

IA Engineer Core Track: LLM Engineering, RAG, QLoRA, Agents

[18-06-2025-]



1.Seccion 1: Week 1 – Build Your First LLM Product: Exploring Top Models

1.1: DIA-1: Ollama: Ejecutar Modelos de IA en local

1.1.1 ¿Qué es Ollama?

Ollama es un programa gratuito y de código abierto que permite **descargar y correr modelos de lenguaje (LLMs) directamente en la propia computadora**, sin necesidad de interne una vez descargado el modelo, sin pagar por uso, y sin enviar los mensajes a ningún servidor externo.

La comunidad lo llama el **"Docker de los modelos lingüísticos"**: abstrae toda la parte técnica (drivers, formatos de archivo, dependencias) y reduce todo a un simple comando de terminal.

¿Qué hace exactamente?

Función	Qué significa
Descarga modelos	<code>ollama pull <modelo></code> baja el modelo desde un repositorio público
Los corre localmente	Carga el modelo en la RAM/GPU y abre un chat interactivo
Gestiona memoria	Carga el modelo cuando se necesita y lo libera al cambiar de modelo
Expone una API local	Levanta un servidor en el puerto 11434, compatible con la API de OpenAI


Por que se usa: privacidad total (nada sale de la PC), sin costo por token, funciona offlina una vez descargado el modelo, y sin pelear con entornos de Python ni drivers de GPU.

1.1.2 Instalación y primeros pasos

El proceso es el mismo en Mac, Windows y Linux — solo cambia la terminal que se usa:

	Mac	Windows
Terminal	Terminal (zsh)	PowerShell
Cómo abrirla	Aplicaciones → Utilidades → Terminal	Menú Inicio → escribir "PowerShell"
Comandos	Idénticos	Idénticos

1. Descargar Ollama desde ollama.com e instalarlo (arrastrar a Aplicaciones en Mac, instalador normal en Windows).
2. Verificar que está instalado, escribiendo en la terminal:



Debería mostrar la lista de comandos disponibles (**serve, create, run, pull, list, etc.**). Nota: en versiones recientes de Ollama puede aparecer un menú interactivo distinto al de versiones antiguas — se sale con la tecla Esc. 3. Confirmar que el servidor ya está corriendo:

```
PS C:\WINDOWS\system32> ollama serve
Error: listen tcp 127.0.0.1:11434: bind: Only one usage of each socket address (protocol/network address/port) is normally permitted.
PS C:\WINDOWS\system32>
```

Si tira un error de "dirección ya en uso" (*address already in use*), es buena señal: significa que Ollama ya está activo en segundo plano.

1.1.3 Comandos básicos de Ollama

Comando	Qué hace
ollama run <modelo>	Descarga el modelo (si no está) y abre un chat interactivo con él
ollama pull <modelo>	Solo descarga el modelo, sin abrir el chat
ollama list	Lista todos los modelos ya descargados en el disco
ollama show <modelo>	Muestra detalles técnicos del modelo (parámetros, arquitectura, etc.)
ollama rm <modelo>	Borra un modelo del disco
Ctrl + D	Sale de la conversación activa con un modelo

1.1.4 Modelos probados en clase

El numero después de los dos puntos en el nombre del modelo indica la cantidad de parámetros (**m** = millones, **b** = mil millones en español)

Modelo	Parámetros	Tamaño disco	Resultado en la prueba
gemma3:270m	270.000.000	292 MB	Respuestas simples, corrió sin problema
phi3 (mini)	3.800.000.000	2.2 GB	Coherente, dio datos curiosos correctos (Torre Eiffel, Joey Chestnut)
gpt-oss:20b	20.900.000.000	13 GB	Descargó y corrió, pero generaba lentitud / se sentía al límite de la RAM — se borró luego con ollama rm

Nota sobre gpt-oss: es un modelo de razonamiento (*reasoning model*). Antes de responder, muestra un bloque "Thinking..." donde razona internamente qué está preguntando el usuario y cómo responder, antes de dar la respuesta final. Misma idea que o1 de OpenAI o el modo "extended thinking" de Claude.

1.1.5 Por que importa la RAM

A diferencia de un video que se puede ir leyendo de a poco, un modelo de lenguaje necesita **TODOS** sus parámetros cargados en memoria al mismo tiempo, porque cada palabra generada requiere cálculos que involucren todos los parámetros.

Regla aproximada: Con la comprensión (quantizacion) que usa Ollama por defecto, cada mil millones de parámetros ocupa aproximadamente 0.5-0.6 GB en memoria.

Ejemplo con gpt-oss:20b → $20.9 \times 0.6 \approx \mathbf{14\ GB}$ solo para cargar el modelo, sin contar el sistema operativo ni otros programas.

Caso de esta PC: 15.8 GB de RAM total. Con eso, gpt-oss:20b queda muy al límite y puede trabarse; phi3 (3.8B) y gemma3:4b son opciones estables sin arriesgar rendimiento.

1.1.6 Que modelo usar según el hardware (vistos en clase)

Modelo	RAM aprox.	Recomendación
<code>gemma3:270m</code>	< 1 GB	Muy liviano, respuestas básicas
<code>phi3</code> (3.8b)	~4-5 GB	Recomendado — estable con 16 GB de RAM
<code>gemma3:4b</code>	~5-6 GB	Alternativa estable, soporta imágenes
<code>gemma3:12b</code>	~10-12 GB	Al límite con 16 GB, no recomendado
<code>gpt-oss:20b</code>	~14-16 GB	No recomendado con 16 GB, riesgo de crasheo

1.1.7 Los modelos más potentes disponibles hoy (2026)

Ojo con algo importante: **no todos los modelos que aparecen en el catálogo de Ollama corren en la propia computadora.** Hay dos tipos:

- **Locales:** se descargan con ollama pull/ollama run y corren 100% en el hardware propio (lo que se estuvo usando toda la clase: Gemma, Phi-3, gpt-oss).
- **:cloud:** llevan ese sufijo en el nombre (ej. **kimi-k2.6:cloud**). Ollama los ejecuta en sus propios servidores — el comando se escribe igual, pero en realidad se le pega por internet a una máquina de Ollama, no a la propia PC. Suelen requerir cuenta y, para los más grandes, un plan pago.

Modelo	Tipo	Parametros totales	Conte xto	RAM/ VRAM real necesaria	Plan de pago necesario	Caso de uso más común	Ejemplo concreto de uso
Kimi K2.6	:cloud únicamente	1.000.000.000 (1T)	256K	~350 GB de RAM/VRAM — imposible en una PC de escritorio o laptop; ni siquiera existe versión descargable, solo corre en servidores de Ollama	Pro (\$20/mes) o Max (\$100/mes) — es de uso "alto"	Agentes autónomos complejos: coordinar hasta 300 sub-agentes en paralelo, tareas de +4.000 llamadas a herramientas	Un equipo de desarrollo le pide "generará un sistema completo de facturación con backend, frontend y tests" y el modelo despliega decenas de sub-agentes que trabajan en paralelo durante horas hasta entregar más de 100 archivos
DeepSeek-V4 Pro	:cloud únicamente	Cientos de miles de millones (MoE)	1M	Decenas a cientos de GB — solo viable en servidores con múltiples GPUs de datacenter	Max (\$100/mes) — es de uso "extra alto"	Razonamiento de frontera y problemas de programación difíciles	Depurar un bug intermitente en un sistema distribuido complejo, donde el modelo tiene que razonar paso a paso sobre condiciones de carrera antes de proponer

							una solución
Llama 4 Maverick	Local (con hardware serio)	400.000.000.000 (MoE)	1M	Decenas de GB de VRAM — requiere una o varias GPUs de gama alta (ej. workstation con 48-80 GB de VRAM)	No aplica (es local, pero necesita GPU propia muy potente)	Documentos o codebases enteros gracias a su contexto de hasta 1 millón de tokens	Cargarle un repositorio entero de una app grande (miles de archivos) en una sola conversación y pedirle que explique cómo se conecta el módulo de pagos con el de usuarios
GLM-5.2 / Mistral Large 3	:cloud principalmente	100.000.000.000+	128K+	40-80 GB de VRAM — GPU de datacenter (ej. A100/H100) o varias GPUs de consumo en paralelo	Pro o Max según el modelo (uso "alto")	Ingeniería de software en repositorios grandes y tareas multilingües/multimodales	Una empresa con equipos en distintos países le pide analizar documentación técnica en inglés, chino y español y generar un resumen unificado con capturas de pantalla incluidas
Qwen3.6: 27b	Local	27.000.000.000	256K	~17 GB de RAM/VRAM — una GPU de 24 GB (ej. RTX 4090) o una Mac con 32 GB de memoria unificada	No aplica (gratis, corre local)	Programación seria, razonamiento y RAG — el más recomendado para un solo modelo local	Un desarrollador o freelance lo usa como asistente de código diario en su PC personal, sin pagar API, para refactorizar funciones y

							escribir tests
Llama 3.3:70b	Local (con GPU potente)	70.000.000.000	128K	~43 GB de VRAM — GPU de gama alta o varias GPUs de consumo combinadas	No aplica (gratis, corre local)	Chat general y RAG (recuperación de documentos) como "caballo de batalla"	Un chatbot interno de una empresa que responde preguntas de empleados consultando manuales internos, corriendo en un servidor propio por temas de privacidad
Gemma 3:27b	Local	27.000.000.000	128K	~17 GB de RAM/VRAM — una GPU de 24 GB o una Mac con 32 GB de memoria unificada	No aplica (gratis, corre local)	Escritura con matices, documentos largos e instrucciones complejas	Redactar y revisar un informe extenso (decenas de páginas) manteniendo un tono consistente de principio a fin
gpt-oss:120b	Local (con GPU potente)	116.830.000.000 (MoE)	128K	~65-80 GB de VRAM — GPU de datacenter de 80 GB (ej. A100/H100)	No aplica (gratis, corre local)	Razonamiento con capacidad cercana a modelos cerrados grandes, en hardware propio de gama alta	Una universidad o laboratorio con un servidor propio lo usa para investigación, evitando mandar datos sensibles a una API externa
gpt-oss:20b (el probado en clase)	Local	20.910.000.000 (MoE)	128K	~16 GB de RAM — una PC doméstica con 16 GB, aunque	No aplica (gratis, corre local)	Chat general y primeras pruebas de razonamiento en una PC doméstica	Justo lo que se hizo en esta clase: instalarlo en una laptop de 16 GB de

	al límite (como se comprob ó en clase)	RAM y probar cómo "piensa" antes de responder, sin depender de internet
--	--	---

Sobre el plan de pago (Ollama Cloud): solo hace falta pagar cuando se quiere usar un modelo con sufijo :cloud (Ollama lo ejecuta en sus servidores). Los modelos **locales** (los que se descargan y corren en la propia PC, como todos los usados en clase) son siempre gratis — lo único que "cuesta" es el hardware propio.

Plan	Precio	Qué incluye
Free	\$0	1 modelo cloud a la vez, uso liviano
Pro	\$20/mes (o \$200/año)	3 modelos cloud a la vez, 50 veces más uso que Free
Max	\$100/mes	10 modelos cloud a la vez, 5 veces más uso que Pro

Conclusión práctica: de los modelos "top" que existen hoy, los más grandes de todos (Kimi K2.6, DeepSeek-V4 Pro) **no se pueden correr localmente ni con la mejor PC de escritorio** — solo están disponibles vía :cloud, o sea, pagándole a Ollama para que lo corra en su infraestructura. El techo real de lo que se puede *descargar y ejecutar en una máquina propia* está en modelos como gpt-oss:120b o llama3.3:70b (necesitan GPUs de gama alta con 40-80 GB de VRAM), y bajando a hardware doméstico normal (16 GB de RAM, como en esta PC), el techo realista sigue siendo gpt-oss:20b o modelos densos de 7B-12B como gemma3:12b o phi3.

Dato interesante: varios de los modelos más grandes (Kimi K2.6, gpt-oss, Llama 4) usan arquitectura **MoE (Mixture of Experts)** — tienen billones de parámetros "guardados", pero por cada palabra que generan solo activan una fracción pequeña de esos parámetros (los "expertos" relevantes para esa tarea). Por eso el uso real de memoria depende más de los parámetros *activos* que de los *totales*.

1.1.8 Como borrar un modelo o desintalar Ollama

Borrar solo un modelo (recomendado si el problema es un modelo puntual, ej. gpt-oss):

```
>>>
PS C:\WINDOWS\system32> ollama rm gpt-oss
deleted 'gpt-oss'
```

Ver qué modelos quedan instalados:

```
deleted 'gpt-oss'
PS C:\WINDOWS\system32> ollama list
NAME          ID          SIZE    MODIFIED
phi3:latest   4f2222927938 2.2 GB  16 minutes ago
gemma3:270m   e7d36fb2c3b3 291 MB  29 minutes ago
```

Desinstalar Ollama por completo (Windows):

1. Inicio → Configuración → Aplicaciones → Aplicaciones instaladas → buscar "Ollama" → Desinstalar.
2. **Importante:** desinstalar el programa NO borra los modelos descargados. Hay que borrar manualmente la carpeta %USERPROFILE%\ollama para recuperar el espacio en disco.

1.2: DIA-1: Roadmap del curso: LLM Engineering (8 semanas)



El recorrido semana a semana

Semana	Tema
1	Fundamentos y la Chat Completions API (<i>estamos acá</i>)
2	Modelos frontera (frontier models) con APIs, interfaces de usuario y multimodalidad
3	Código abierto con Hugging Face
4	Selección de LLMs y generación de código
5	RAG y Question Answering — creando un "experto"
6	Fine-tuning de un modelo frontera
7	Fine-tuning de un modelo de código abierto
8	El final — IA agéntica

Al completar la semana 8, el objetivo declarado del profesor es que el alumno pueda decir "ahora soy ingeniero LLM" — llegar a ese hito de dominio del tema.

1.2.1 La lógica del curso: construye sobre lo anterior

El profesor remarca que el curso "se construye y se construye y se construye" — no son 8 temas sueltos, sino una progresión:

1. **Primero, panorama de modelos** — variedad de LLMs, tanto de código abierto como cerrado (lo que se estuvo haciendo con Ollama: Gemma, Phi-3, gpt-oss).
2. **Después, las herramientas** – kits y librerías para trabajar con esos LLMs.
3. **Luego, las técnicas** – formas de sacarles el máximo rendimiento a los modelos
4. **Y todo el tiempo, proyectos reales** — el profesor insiste en que la mejor forma de aprender es construyendo proyectos comerciales grandes, no solo teoría.

1.2.2 Las 3 técnicas centrales que se van a cubrir

Técnica	Para que sirve
RAG (Retrieval-Augmented Generation)	Darle a un modelo acceso a información externa (documentos propios) para que responda con datos que no tenía en su entrenamiento
Fine-tuning	Ajustar/entrenar un modelo existente con datos propios para especializarlo en una tarea
Agents (agentes)	Que un modelo pueda actuar de forma autónoma, tomando decisiones y usando herramientas por su cuenta

1.2.3 Las herramientas/frameworks que se van a usar

Herramienta	Para que
Hugging Face	Plataforma central de modelos de código abierto. Es una plataforma colaborativa de código abierto considerada el “Github de la IA”, donde millones de desarrolladores comparten modelos, datos y aplicaciones de aprendizaje automático.
Gradio	Crear interfaces de usuario rápidas para probar modelos
LangChain	Framework para encadenar llamadas a LLMs y construir aplicaciones
W&B (Weights & Biases)	Seguimiento y registro de experimentos de entrenamiento
Modal	Infraestructura en la nube para correr cargas de trabajo pesadas (ej. entrenamiento con GPU)

1.2.4 Los modelos que se van a explorar a lo largo del curso

Modelos cerrados (frontera):

- GPT-5 (OpenAI)
- Claude (Anthropic)
- Gemini (Google)

Modelos de código abierto:

- Llama (Meta)
- Phi (Microsoft) — ya probado en Ollama
- Qwen (Alibaba)

1.2.5 Tipos de proyectos que vas a construir

El profesor menciona explícitamente:

- Proyectos **multimodales** (texto, imagen, etc. Combinados)
- Aplicaciones **comerciales de consumo**
- Algo más técnico: **portar código de un lenguaje a otro**
- Proyectos que involucran **vectores** (embeddings, bases de datos vectoriales — clave para RAG)
- **Entrenamiento con GPUs** a mayor escala
- Un **gran proyecto comercial final**, al cierre de las 8 semanas.

1.2.6 Ejemplo práctico mostrado en el video

Como cierre de la parte de Ollama, el profesor mostró un caso de uso real con gpt-oss corriendo local: le pidió que actuara de **tutor de español para principiantes**. El modelo:


1. Mostró su bloque de "pensamiento" (Thinking...) antes de responder
2. Se presentó en español como tutor, con un tono natural y cercano
3. Empezó una conversación guiada paso a paso (saludo → preguntar el nombre → preguntar de dónde es, etc.)

El profesor lo usa como ejemplo de que, incluso con un modelo corriendo 100% local en la propia PC, ya se puede obtener valor real — comparable a funcionalidades que ofrece una app comercial como Duolingo.

1.3 DIA-1: Configuración del entorno y primeros paso

How you will level up in Week 1

You will understand Frontier Models and their APIs and will have coded your own solutions



Start | Day 1 (today) | Day 2 | Day 3 | Day 4 | Day 5 | End

Day 1 (today)
Your first LLM solution from scratch

Day 2
Best positioning you for success in 8 weeks


Day 3
State of the Art - comparing Frontier models

Day 4
Transformers

Day 5
A powerful solution in a matter of minutes

Creating a full powered Data Science Environment

It's not as easy as I'd like...



Step 1
Clone the repo, install Cursor
Open the project

Step 2
Install the wonderful uv
Set up your environment

Step 3
Create an OpenAI key

Step 4
Create the .env file

Step 5
Start Week 1 Day 1

Cómo se avanza en la Semana 1

Día	Qué se logra
Día 1 (hoy)	Primera solución LLM construida desde cero
Día 2	Mejor posicionamiento para tener éxito en las 8 semanas
Día 3	Estado del arte — comparando modelos frontera
Día 4	Transformers (primeras intuiciones)
Día 5	Una solución potente construida en cuestión de minutos (producto comercial)

Entender los **modelos frontera y sus APIs**, y haber programado soluciones propias con ellos.

1.3.1 Que es un “modelo frontera” (frontier model)

Es el término que usa la industria para referirse a los **modelos más recientes y potentes disponibles**, la vanguardia de lo que es posible en cada momento (ej. GPT-5, Claude, Gemini) — a diferencia de los modelos de código abierto más chicos que se venían probando con Ollama.

1.3.2 Los 5 pasos para armar el entorno de trabajo + ¿Que es uv? + Por que UV y no Anaconda

El profesor advierte que configurar el entorno "no es tan fácil como me gustaría" y que ~80% de las preguntas que recibe son justamente sobre este proceso — pero también aclara que la documentación del curso ya cubre la gran mayoría de los problemas comunes.

Paso	Qué implica
1. Cimientos	Clonar el repositorio del curso desde GitHub, instalar Cursor (editor recomendado, aunque se puede usar cualquier otro) y abrir el proyecto
2. Entorno Python	Instalar uv , una alternativa moderna a Anaconda para gestionar dependencias de Python
3. Clave de API	Crear una API key de OpenAI. Implica un gasto mínimo (~\$5 USD), aunque existe una alternativa gratuita documentada para quien no quiera pagar
4. Variables de entorno	Agregar la clave al archivo <code>.env</code> . Punto común de errores: nombre mal escrito del archivo o de la variable
5. Arrancar	No hay paso 5 real — simplemente empezar la Semana 1, Día 1

¿Qué es exactamente uv?

Uv es un gestor de paquetes y proyectos de Python de nueva generación, escrito en **Rust** por la empresa **Astral** (los mismos creados del linter Ruff). Funciona como reemplazo directo (*drop-in replacement*) de las herramientas tradicionaels de Python.

En vez de necesitar varias herramientas separadas, uv las reemplaza a **todas en un solo binario**:

Herramienta tradicional	Para qué servía	Comando equivalente en uv
<code>pip</code>	Instalar paquetes	<code>uv add</code>
<code>pip-tools</code>	Congelar versiones de dependencias	<code>uv lock</code>
<code>venv</code>	Crear entornos virtuales	<code>uv venv</code>
<code>pyenv</code>	Gestionar versiones de Python	<code>uv python install</code>
<code>pipx</code>	Instalar herramientas de línea de comandos	(incluido)
Poetry / PDM	Gestión de proyectos completos	(incluido)

Herramienta tradicional	Para que servia	Comando equivalente en uv
Pip	Instalar paquetes	Uv add
pip-tools	Congelar versiones de dependencias	Uv lock
Venv	Crear entornos virtuales	uv venv
Pyenv	Gestionar versiones de Python	uv python install
Pipx	Instalar herramientas de línea de comandos	(incluido)
Poetry / PDM	Gestión de proyectos completos	(incluido)

Por qué es tan popular: su ventaja principal es la velocidad — es entre **10 y 100 veces más rápido** que pip para instalar paquetes (por ejemplo, un proyecto con librerías pesadas como Django, Celery, Pandas y scikit-learn que con pip tarda ~90 segundos, con uv tarda ~8 segundos). Esto se debe a estar escrito en Rust y usar un caché global que evita volver a descargar paquetes ya instalados en otros proyectos.

Dato reciente (2026): en marzo de 2026, **OpenAI adquirió Astral** (la empresa detrás de uv) para integrarlo en su plataforma Codex – lo cual confirma que tan relevante se volvió esta herramienta dentro del ecosistema de IA, mas allá de ser “solo” un gestor de paquetes de Python.

Por qué UV y no Anaconda

El profesor lo destaca porque normalmente hay que elegir 2 de 3 entre: **fácil, rápido, confiable**. Según él, UV logra las tres cosas a la vez, y por eso ganó tanta popularidad en la comunidad.

1.4 DIA-1: Entorno desarrollo, notebooks Jupyter y primera llamada a modelo frontier (Gemini) + scraper.py – consultar: <https://aistudio.google.com/>

Archivo: dia1.ipynb

```
# imports

import os
from dotenv import load_dotenv
from scraper import fetch_website_contents
from IPython.display import Markdown, display
from google import genai

# Si obtienes un error al ejecutar esta celda, ¡por favor ve al notebook de
solución de problemas!
```

Python

python

```
from scraper import fetch_website_contents
```

Importa la función `fetch_website_contents` **desde tu propio archivo** `scraper.py` (el que vimos que ya está en tu carpeta `week1`). Esa función es la que descarga y limpia el texto de una página web.

python

```
from IPython.display import Markdown, display
```

Trae dos herramientas para **mostrar bonito** el resultado en el notebook: `Markdown` da formato de texto enriquecido (títulos, negritas), y `display` lo renderiza en pantalla en vez de mostrarlo como texto plano.

python

```
from google import genai
```

Esta es la línea que ya **adaptaste** vos (en el original decía `from openai import OpenAI`) — trae el paquete de Google para poder llamar a Gemini.

1.4.1 Archivo: scraper.py

```
dia1.ipynb U X scraper.py U X
week1 > scraper.py > fetch_website_contents
1 from bs4 import BeautifulSoup
2 import requests
3
4
5 # Standard headers to fetch a website
6 headers = {
7     "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.
8     36 (KHTML, like Gecko) Chrome/117.0.0.0 Safari/537.36"
9 }
10
11 def fetch_website_contents(url):
12     """
13     Return the title and contents of the website at the given url;
14     truncate to 2,000 characters as a sensible limit
15     """
16     response = requests.get(url, headers=headers)
17     soup = BeautifulSoup(response.content, "html.parser")
18     title = soup.title.string if soup.title else "No title found"
19     if soup.body:
20         for irrelevant in soup.body(["script", "style", "img", "input"]):
21             irrelevant.decompose()
22         text = soup.body.get_text(separator="\n", strip=True)
23     else:
24         text = ""
25     return (title + "\n\n" + text)[:2_000]
26
27
28 def fetch_website_links(url):
29     """
30     Return the links on the website at the given url
31     I realize this is inefficient as we're parsing twice! This is to keep the
32     code in the lab simple.
33     Feel free to use a class and optimize it!
34     """
35     response = requests.get(url, headers=headers)
36     soup = BeautifulSoup(response.content, "html.parser")
37     links = [link.get("href") for link in soup.find_all("a")]
38     return [link for link in links if link]
```

Los imports

```
python
from bs4 import BeautifulSoup
import requests
```

- **Request:** librería para hacer pedidos HTTP — básicamente, "pedirle" a un sitio web que te mande su contenido (como cuando tu navegador visita una página, pero hecho desde código).
- **BeautifulSoup:** librería para "entender" el HTML que devuelve la web. El HTML crudo es un lío de etiquetas (<div>, <script>, <p>, etc.); BeautifulSoup te deja navegarlo y sacar lo que te interesa.

Los headers

```
python
headers = {
    "User-Agent": "Mozilla/5.0 ..."
}
```

Esto le dice al sitio web "soy un navegador Chrome normal", en vez de decir "soy un script de Python". Muchos sitios bloquean pedidos que no parecen venir de un navegador real — este header ayuda a evitar ese bloqueo.

1.4.1.1 def fetch_website_contents(url):

```
0
1 def fetch_website_contents(url):
2     """
3     Return the title and contents of the website at the given url;
4     truncate to 2,000 characters as a sensible limit
5     """
6     response = requests.get(url, headers=headers)
7     soup = BeautifulSoup(response.content, "html.parser")
8     title = soup.title.string if soup.title else "No title found"
9     if soup.body:
10         for irrelevant in soup.body(["script", "style", "img", "input"]):
11             irrelevant.decompose()
12         text = soup.body.get_text(separator="\n", strip=True)
13     else:
14         text = ""
15     return (title + "\n\n" + text)[:2_000]
16
```

```
response = requests.get(url, headers=headers)
```

Le pide al servidor de esa url que le mande la página. headers es el diccionario que vimos antes, simulando ser un navegador. response guarda todo lo que devuelve el servidor (el HTML, el código de estado, etc.).

```
soup = BeautifulSoup(response.content, "html.parser")
```

Toma response.content (el HTML crudo, en bytes) y lo convierte en un objeto soup — una estructura que Python puede recorrer y buscar dentro, en vez de tratarlo como texto plano sin sentido.

```
title = soup.title.string if soup.title else "No title found"
```

Es un if compacto en una línea: "si existe una etiqueta <title> en la página, sacale el texto; si no existe, usá el string 'No title found'".

```
if soup.body:
```

Chequea si la página tiene una etiqueta <body> (el cuerpo visible de la página, donde está el contenido real). Algunas páginas raras o rotas podrían no tenerla.

```
for irrelevant in soup.body(["script", "style", "img", "input"]):
    irrelevant.decompose()
```

Este es el paso de limpieza: busca **todas** las etiquetas <script>, <style>, e <input> dentro del body, y con **.decompose()** las **elimina por completo** del árbol. Son cosas que no aportan texto legible (código JavaScript, hojas de estilo, imágenes, campos de formulario).

```
text = soup.body.get_text(separator="\n", strip=True)
```

Una vez limpio, saca **solo el texto** que queda (sin etiquetas HTML), separando cada bloque de texto con un salto de línea (**\n**), y quitando espacios sobrantes al principio/final (**strip=True**).

```
else:
    text = ""
```

Si no había <body> (el if de arriba dio falso), el texto queda vacío en vez de fallar con un error.

```
return (title + "\n\n" + text)[:2_000]
```

Junta el título y el texto con dos saltos de línea entre medio, y corta el resultado a los primeros **2.000 caracteres** ([:2_000] es slicing de Python — el guion bajo en 2_000 es solo para que sea más legible, equivale a 2000). Esto evita mandar textos gigantes al modelo.

1.4.1.2 def fetch_website_links(url) + Para que sirve esta función en el curso

```
def fetch_website_links(url):
    """
    Return the links on the website at the given url
    I realize this is inefficient as we're parsing twice! This is to keep the
    code in the lab simple.
    Feel free to use a class and optimize it!
    """
    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.content, "html.parser")
    links = [link.get("href") for link in soup.find_all("a")]
    return [link for link in links if link]
```

```
def fetch_website_links(url):
    """
    Return the links on the website at the given url
    I realize this is inefficient as we're parsing twice! This is to keep the
    code in the lab simple.
    Feel free to use a class and optimize it!
    """
    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.content, "html.parser")
    links = [link.get("href") for link in soup.find_all("a")]
    return [link for link in links if link]
```

El docstring — acá el profesor deja una nota honesta: admite que es ineficiente, porque si necesitás texto Y enlaces de la misma página, terminás descargando y parseando dos veces (una por cada función). Lo dejó así a propósito para que el código del laboratorio sea simple de entender, e invita a optimizarlo con una clase si alguien quiere.

Te armo un ejemplo concreto mostrando **las dos formas**: la actual (ineficiente, dos requests) y la optimizada con una clase (una sola request), tal como invita a hacer el profesor.

python

```
# Si querés texto Y links de la misma página, hacés esto:
contenido = fetch_website_contents("https://edwarddonner.com") # Request #1: descarga la página
links = fetch_website_links("https://edwarddonner.com") # Request #2: descarga la MISMA página de nuevo
```

Acá el problema es claro: `requests.get()` se ejecuta **dos veces** contra el mismo sitio, cuando en realidad ya tenías toda la información descargada la primera vez.

Forma optimizada: una clase que descarga una sola vez

```
class Website:
    def __init__(self, url):
        response = requests.get(url, headers=headers)
        self.soup = BeautifulSoup(response.content, "html.parser") # Un solo request, un solo parseo
        self.title = self.soup.title.string if self.soup.title else "No title found"

    def get_contents(self):
        if self.soup.body:
            for irrelevant in self.soup.body(["script", "style", "img", "input"]):
                irrelevant.decompose()
            text = self.soup.body.get_text(separator="\n", strip=True)
        else:
            text = ""
        return (self.title + "\n\n" + text)[:2_000]

    def get_links(self):
        links = [link.get("href") for link in self.soup.find_all("a")]
        return [link for link in links if link]
```

Y así se usaría:

```
ed = Website("https://edwarddonner.com") # Un solo request acá, en __init__

contenido = ed.get_contents() # Reusa el mismo soup ya descargado
links = ed.get_links() # Reusa el mismo soup de nuevo, sin volver a pedir nada
```

La diferencia clave

	Funciones sueltas (actual)	Clase (optimizada)
Requests HTTP si necesitás ambas cosas	2	1
Cuándo se descarga la página	Cada vez que llamás a una función	Solo una vez, al crear el objeto (<code>__init__</code>)
Dónde vive el <code>soup</code>	Variable local, se pierde al terminar la función	Guardado en <code>self.soup</code> , reutilizable

```
def fetch_website_links(url):
    """
    Return the links on the webiste at the given url
    I realize this is inefficient as we're parsing twice! This is to keep the
    code in the lab simple.
    Feel free to use a class and optimize it!
    """
    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.content, "html.parser")
    links = [link.get("href") for link in soup.find_all("a")]
    return [link for link in links if link]
```

Exactamente lo mismo que en `fetch_website_contents`: descarga el HTML y lo convierte en un objeto navegable con BeautifulSoup.

```
def fetch_website_links(url):
    """
    Return the links on the webiste at the given url
    I realize this is inefficient as we're parsing twice! This is to keep the
    code in the lab simple.
    Feel free to use a class and optimize it!
    """
    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.content, "html.parser")
    links = [link.get("href") for link in soup.find_all("a")]
    return [link for link in links if link]
```

Esta línea tiene dos partes:

- `soup.find_all("a")` busca **todas** las etiquetas `<a>` de la página — en HTML, `<a>` es la etiqueta que crea un enlace (link).
- `link.get("href")` saca el atributo `href` de cada una — es decir, la URL a la que apunta ese enlace.
- Todo dentro de `[...]` es una **list comprehension**: una forma compacta de escribir un loop que arma una lista. Equivale a:

```
def fetch_website_links(url):  
    """  
    Return the links on the website at the given url  
    I realize this is inefficient as we're parsing twice! This is to keep the  
    code in the lab simple.  
    Feel free to use a class and optimize it!  
    """  
    response = requests.get(url, headers=headers)  
    soup = BeautifulSoup(response.content, "html.parser")  
    links = [link.get("href") for link in soup.find_all("a")]  
    return [link for link in links if link]
```

Esta línea tiene dos partes:

- `soup.find_all("a")` busca **todas** las etiquetas `<a>` de la página — en HTML, `<a>` es la etiqueta que crea un enlace (link).
- `link.get("href")` saca el atributo `href` de cada una — es decir, la URL a la que apunta ese enlace.
- Todo dentro de `[...]` es una **list comprehension**: una forma compacta de escribir un loop que arma una lista.

Para qué sirve esta función en el curso

Todavía no se usa en el primer laboratorio (el que armaste), pero es la base para algo que vas a construir más adelante: en vez de resumir solo una página, el programa podría **seguir los enlaces** que encuentra ahí (por ejemplo, la página "About" o "Careers" de una empresa) y armar un resumen combinando varias páginas — algo que el profesor menciona que van a hacer en labs siguientes de la semana 1.

1.4.2 genai.Client – la llamada al modelo (primer hola mundo desde llm engineering)

```
# Para darte un adelanto -- llamar a Gemini con este mensaje es así de fácil. Si
tienes problemas, ve al notebook de Solución de problemas.

message = "¡Hola, Gemini! ¡Este es mi primer mensaje para ti! ¡Hola!"

messages = [{"role": "user", "content": message}]

messages

client = genai.Client(api_key=os.getenv('GOOGLE_API_KEY'))

response = client.models.generate_content(model="gemini-2.5-flash", contents=message)
response.text
```

Línea por línea

```
client = genai.Client(api_key=os.getenv('GOOGLE_API_KEY'))

response = client.models.generate_content(model="gemini-2.5-flash", contents=message)
response.text
```

- **os.getenv('GOOGLE_API_KEY')**: va a buscar el valor de esa variable en tu archivo .env (el que cargaste antes con load_dotenv()).
- **genai.Client(api_key=...)**: crea un **objeto cliente** — básicamente, tu "conexión" con los servidores de Google, autenticada con tu clave. Es el equivalente exacto de lo que era `openai = OpenAI()` en la versión original, pero para Gemini.
- Se guarda en la variable `client`, que vas a usar para hacer cualquier llamada al modelo de acá en adelante.

```
client = genai.Client(api_key=os.getenv('GOOGLE_API_KEY'))

response = client.models.generate_content(model="gemini-2.5-flash", contents=message)
response.text
```

- **client.models.generate_content(...)**: es el método que efectivamente **manda el mensaje** y espera la respuesta del modelo — la llamada real a la API, viajando por internet hasta los servidores de Google.
- **model="gemini-2.5-flash"**: le decís qué modelo específico querés usar (el mismo que vimos antes en tu tabla de límites gratuitos).
- **contents=message**: acá le pasás el mensaje. A diferencia de OpenAI (que necesita la lista de diccionarios con **role/content**), Gemini para un mensaje simple acepta directamente un **string** — mucho más corto de escribir.
- Todo lo que devuelve el servidor queda guardado en la variable **response**.

```
>
client = genai.Client(api_key=os.getenv('GOOGLE_API_KEY'))

response = client.models.generate_content(model="gemini-2.5-flash", contents=message)
response.text

[]
```

El objeto response trae mucha información (metadatos, tokens usados, etc.), pero `.text` es el atributo que contiene específicamente el texto de la respuesta del modelo — lo que realmente te interesa leer.

Comparación directa con la versión de OpenAI que reemplazaste

	OpenAI (original)	Gemini (tu versión)
Crear el cliente	<code>openai = OpenAI()</code>	<code>client = genai.Client(api_key=...)</code>
Hacer la llamada	<code>openai.chat.completions.create(model=..., messages=messages)</code>	<code>client.models.generate_content(model=..., contents=message)</code>
Formato del mensaje	Lista de diccionarios <code>[{"role": "user", "content": "..."}]</code>	String simple: <code>"Hola, GPT!"</code>
Sacar el texto de respuesta	<code>response.choices[0].message.content</code>	<code>response.text</code>

A ultimo momento se cambio el modelo por estar descontinuado a Gemini 3.6 flash:

```
client = genai.Client(api_key=os.getenv('GOOGLE_API_KEY'))

response = client.models.generate_content(model="gemini-3.6-flash", contents=message)
response.text

[10] ✓ 5.1s
```

1.4.3 Dos tipos de prompts: System prompt – User prompt

Este bloque te muestra los **dos tipos de instrucciones** que se le pueden dar a un modelo, y cómo se pasan en Gemini específicamente.

Los dos tipos de prompts

Tipo	Para que sirve	Ejemplo
System prompt	Define la tarea y el tono general que debe adoptar el modelo, durante toda la conversación	"Sos un asistente sarcástico que resume webs"
User prompt	El mensaje concreto del usuario, al que el modelo tiene que responder respetando el tono del system prompt	"¿Cuánto es 2 + 2?"

Es la diferencia entre "**cómo tenés que comportarte**" (system) y "**qué te estoy pidiendo ahora**" (user).

El formato de OpenAI (referencia, no es tu código)

```
python
[
  {"role": "system", "content": "aquí va el mensaje del sistema"},
  {"role": "user", "content": "aquí va el mensaje del usuario"}
]
```

1.4.3.1 Código de gpt vs Gemini

Código de GPT

```
messages = [
  {"role": "system", "content": "You are a snarky assistant"},
  {"role": "user", "content": "What is 2 + 2?"}
]

response = openai.chat.completions.create(model="gpt-4.1-nano", messages=messages)
response.choices[0].message.content
```

✓ 1.1s

Código de Gemini

```
response = client.models.generate_content(
  model="gemini-2.5-flash",
  config=genai.types.GenerateContentConfig(system_instruction="Eres un asistente útil"),
  contents="¿Cuánto es 2 + 2?"
)
response.text
```

Acá está la diferencia clave con OpenAI: Gemini no usa una lista de diccionarios con **role**. En cambio:

- **system_instruction="Eres un asistente útil"** → va dentro de un objeto especial llamado **GenerateContentConfig**, pasado en el parámetro **config**. Es el equivalente exacto al mensaje **role: "system"** de OpenAI.
- **contents="¿Cuánto es 2 + 2?"** → es directamente un string simple con el mensaje del usuario. Es el equivalente al **role: "user"**.

Comparación lado a lado

	OpenAI	Gemini
System prompt	<code>{"role": "system", "content": "..."} dentro de la lista</code>	<code>system_instruction="..."</code> dentro de <code>GenerateContentConfig</code>
User prompt	<code>{"role": "user", "content": "..."} dentro de la lista</code>	<code>contents="..."</code> directo como string
Estructura general	Una sola lista con todo mezclado	Dos parámetros separados: <code>config</code> y <code>contents</code>

1.4.4 Usando Ollama con llama3.2 (alternativa local a OpenAI)

1.4.4.1 Modelos de Ollama probados en el curso

Modelo	Parámetros	Tamaño en disco	RAM aprox.	Comando de descarga
gemma3:270m	270.000.000	292 MB	<1 GB	ollama pull gemma3:270m
phi3 (mini)	3.800.000.000	2.2 GB	~4-5 GB	ollama pull phi3
llama3.2	3.000.000.000	2.0 GB	~4-5 GB	ollama pull llama3.2
gpt-oss:20b	20.900.000.000	13 GB	~14-16 GB	ollama pull gpt- oss:20b

Modelo	Parametros	Tamaño en disco	RAM aprox.	Comando de descarga
gemma3:270m	270.000.000	292 MB	< 1 GB	ollama pull gemma3:270m
phi3 (mini)	3.800.000.000	2.2 GB	~4-5 GB	ollama pull phi3
llama3.2	3.000.000.000	2.0 GB	~4-5 GB	ollama pull llama3.2
gpt-oss:20b	20.900.000.000	13 GB	~14-16 GB	ollama pull gpt- oss:20b

llama3.2 queda en el mismo rango liviano que phi3 — ambos corren sin problema con 15.8 GB de RAM disponibles en esta PC, muy lejos del límite que sí generaba lentitud con gpt-oss:20b.

1.4.4.2 ¿Por qué se usa la clase OpenAI para hablar con Ollama? + ¿Por qué el curso usa la vía "OpenAI" y no ollama.chat(...) directamente?

A simple vista puede parecer raro: si en el resto del curso se venía usando google-genai para Gemini, ¿por qué acá aparece de nuevo **OpenAI(...)**?

La razón no es que Ollama no tenga forma de hablarle desde Python — de hecho, Ollama tiene su propia librería (ollama, con funciones como ollama.chat(...)). Lo que pasa es que, además de esa librería propia, Ollama expone un servidor local que **imita el formato de la API de OpenAI** (esto es oficial y documentado por Ollama, aunque ellos mismos lo marcan como "experimental"). Es decir, Ollama "finge" ser OpenAI de cara al código: acepta las mismas rutas, el mismo formato de messages, y devuelve las respuestas con la misma forma (response.choices[0].message.content).

¿Por qué el curso usa la vía "OpenAI" y no ollama.chat(...) directamente?

Las dos opciones funcionan igual de bien para lo que se necesita acá. La diferencia es de conveniencia, no de capacidad:

	Librería propia (<code>ollama.chat(...)</code>)	Vía compatible con OpenAI (<code>OpenAI(base_url=...)</code>)
Código nuevo que aprender	Sí, una API distinta a la que ya se usó con OpenAI	No — es literalmente el mismo código que ya viste antes
Cambiar de proveedor más adelante	Habría que reescribir las llamadas	Solo cambiar <code>base_url</code> y el nombre del modelo
Objetivo pedagógico del curso	—	Mostrar que distintos proveedores (OpenAI, Ollama, y otros) pueden compartir una única forma de escribir el código

El curso ya te había enseñado el patrón `openai.chat.completions.create(...)` para hablar con OpenAI en la nube. Al usar la misma clase para Ollama, el profesor evita enseñarte una API nueva desde cero — reaprovechás todo lo que ya sabés, y el único cambio real es **a dónde apunta** el cliente (`base_url`). Es una elección didáctica: menos cosas nuevas que memorizar, más foco en entender el concepto de "modelo local vs modelo en la nube".

Por eso, en vez de escribir un cliente nuevo desde cero, el curso reutiliza la clase OpenAI ya conocida, y el único cambio real es decirle **a qué dirección apuntar**:

```
# Aquí está -- mira el base_url
openai = OpenAI(base_url='http://localhost:11434/v1', api_key='ollama')
```

✓ 0.2s Python

Base_url es el parámetro que redirige el tráfico: en vez de ir a los servidores de OpenAI, va al puerto **11434** de la propia PC, donde Ollama está escuchando pedidos con ese mismo formato.

1.4.4.3 ¿Se podría hacer lo mismo, pero con el cliente de Gemini (genai.Client)? + Resumen + idea clave + conectar el cliente a Ollama

No directamente. El cliente **genai.Client** de Google si permite cambiar la URL de destino (con el parámetro **http_options**, como en el ejemplo de abajo), pero eso solo sirve si del otro lado hay un servidor que hable el **protocolo de Gemini** – y Ollama no lo tiene. Está confirmado en la documentación oficial de Ollama: los únicos endpoints que expone son los que imitan a OpenAI (**/v1/chat/completions**, **/v1/completions**, **/v1/embeddings**, **/v1/responses**) — no hay ninguna ruta que hable el formato de Gemini.

Así se vería si Ollama sí ofreciera compatibilidad con el protocolo de Gemini (a modo de referencia, **esto no funciona con Ollama tal cual está hoy**):

```
python

from google import genai
from google.genai.types import HttpOptions

# Esto NO funciona contra Ollama, porque Ollama no habla el protocolo de Gemini
client = genai.Client(
    api_key="ollama",
    http_options=HttpOptions(base_url="http://localhost:11434/v1")
)
```

En resumen

	Cliente de OpenAI + Ollama	Cliente de Gemini + Ollama
¿Funciona?	Sí, porque Ollama imita el protocolo de OpenAI	No, porque Ollama no habla el protocolo de Gemini
Qué hay que cambiar	Solo <code>base_url</code> y <code>api_key</code>	No hay forma directa sin un traductor de protocolos de por medio

	Cliente de OpenAI + Ollama	Cliente de Gemini + Ollama
¿Funciona?	Sí, porque Ollama imita el protocolo de OpenAI	No, porque Ollama no habla el protocolo de Gemini
Qué hay que cambiar	Solo <code>base_url</code> y <code>api_key</code>	No hay forma directa sin un traductor de protocolos de por medio

Por eso, para hablar con modelos locales de Ollama desde este notebook, conviene seguir usando la clase **OpenAI** (redirigida con **base_url**), tal como lo hace el curso — no la de **google-genai**.

La idea clave

Ollama imita la API de OpenAI, así que se puede reusar el mismo cliente **OpenAI()** de siempre, solo redirigiéndolo a la propia PC en vez de a los servidores de OpenAI — el truco está en el **base_url**.

Conectar el cliente a Ollama

```
> <
# Aquí está -- mira el base_url

openai = OpenAI(base_url='http://localhost:11434/v1', api_key='ollama')

[2] ✓ 0.2s
Generate + Code + Markdown Python
```

- **base_url='http://localhost:11434/v1'**: redirige el cliente a **la propia máquina (localhost)**, en el puerto **11434**, donde corre Ollama.
- **api_key='ollama'**: valor de relleno. Ollama no valida autenticación real, pero el parámetro es obligatorio en la librería, así que se le pasa cualquier texto.

1.4.4.4 Primera llamada: solo mensaje de usuario + Segunda llamada: con system prompt y user prompt + El modelo llama3.2 en si

```
# Para darte un adelanto -- llamar a OpenAI con estos mensajes es así de fácil. Si
tienes problemas, ve al notebook de Solución de problemas.

message = "¡Hola, Llama! ¡Este es mi primer mensaje para ti! ¡Hola!"
response = openai.chat.completions.create(model="llama3.2", messages=
[{"role": "user", "content": message}])
print(response.choices[0].message.content)

] ✓ 24.4s
Python
```

El resto del código es **idéntico** al que se usa con OpenAI en la nube: mismo formato de messages (lista de diccionarios con role/content), misma forma de leer response.choices[0].message.content. Solo cambia el nombre del modelo (llama3.2) y que ahora openai apunta a la PC local.

Segunda llamada: con system prompt y user prompt

```
# Para darte un adelanto -- llamar a OpenAI con mensajes de system y user:

response = openai.chat.completions.create(model="llama3.2", messages=messages)
print(response.choices[0].message.content)

[3] ✓ 4.5s
Python
```

Aca **messages** ya viene armada de antes con los dos roles (**system** y **user**) – la llamada funciona exactamente igual que con un modelo de OpenAI en la nube, sin cambiar la estructura.

Respuesta:

```
Genial, un pregunta que solo una persona completamente normal y no confundida habría hecho antes de nacer.

La respuesta es: 4. ¿Eso te ha dejado atónito?
```

El modelo: llama3.2

- Descargado con `ollama pull llama3.2`
- **3B parámetros, 2.0 GB** en disco
- Tamaño similar a phi3 (ya probado con éxito antes en esta PC de 15.8 GB de RAM)
- Corre sin problema, muy por debajo del límite de RAM disponible

1.4.4.5 Por que esto importa

Confirma que la API de OpenAI se volvió un estándar de facto en la industria: muchos proveedores ofrecen una capa de compatibilidad que imita ese formato, para que el mismo código funcione con mínimos cambios en distintos backends.

- **Ollama:** como se vio en este documento, solo cambiando `base_url` y `api_key`.
- **Claude (Anthropic):** también ofrece esta compatibilidad — cambiando `base_url` a `https://api.anthropic.com/v1/`, la API key por una de Anthropic, y el nombre del modelo, el mismo código de la clase OpenAI funciona con Claude. Sin embargo, Anthropic aclara que esta capa está pensada solo para **pruebas y evaluación rápida**, no para producción: tiene limitaciones (no soporta embeddings, el parámetro `n` no funciona, el "extended thinking" no devuelve el razonamiento paso a paso como sí lo hace la API nativa de Claude).

```
import os
from openai import OpenAI

client = OpenAI(
    api_key=os.environ.get("ANTHROPIC_API_KEY"), # clave de Claude, no de OpenAI
    base_url="https://api.anthropic.com/v1/",    # apunta a los servidores de Anthropic
)

response = client.chat.completions.create(
    model="claude-opus-5", # nombre de un modelo de Claude
    messages=[
        {"role": "system", "content": "Eres un asistente útil"},
        {"role": "user", "content": "¿Quién eres?"},
    ],
)
print(response.choices[0].message.content)
```

El código es prácticamente idéntico al de Ollama (misma clase OpenAI, mismo método `.chat.completions.create(...)`), solo cambian los tres datos: `base_url`, `api_key` y `model`.

Pero Anthropic también tiene su propio SDK nativo, igual que Google tiene `google-genai`. Se llama simplemente `anthropic`, y es lo que la propia Anthropic recomienda usar en vez de la capa de compatibilidad con OpenAI, justo por las limitaciones que se mencionaron arriba:

```
python
import os
from anthropic import Anthropic

client = Anthropic(api_key=os.environ.get("ANTHROPIC_API_KEY"))

message = client.messages.create(
    model="claude-opus-5",
    max_tokens=1024,
    messages=[
        {"role": "user", "content": "¿Quién eres?"}
    ]
)
print(message.content)
```

Notar las diferencias con el SDK nativo:

- Se importa `Anthropic` (no `OpenAI`)
- El método se llama `.messages.create(...)` (no `.chat.completions.create(...)`)

- Pide `max_tokens` como parámetro obligatorio
- La respuesta viene en `message.content` en vez de `response.choices[0].message.content`

¿Y este SDK nativo de Anthropic también se puede apuntar a Ollama?

El cliente `Anthropic(...)` sí acepta un parámetro `base_url`, igual que la clase `OpenAI`. Pero **no sirve para conectarlo a Ollama**, por la misma razón que pasaba con Gemini: `base_url` solo redirige a *dónde* va el pedido, no cambia *el formato* del pedido. El SDK nativo de Anthropic arma sus pedidos siguiendo el protocolo propio de Anthropic (endpoint `/v1/messages`, con su estructura particular), y Ollama no entiende ese formato — solo entiende el de `OpenAI`.

```
python

from anthropic import Anthropic

# Esto NO funciona contra Ollama, aunque el parámetro exista:
# Ollama no habla el protocolo /v1/messages de Anthropic
client = Anthropic(
    api_key="ollama",
    base_url="http://localhost:11434"
)
```

Por eso, para hablar con Ollama desde Python solo hay dos caminos reales: usar la clase `OpenAI` (redirigida con `base_url`, como se mostró al principio de este documento), o usar la librería propia de Ollama (`ollama.chat(...)`).

- **Gemini**: es la excepción entre los tres — no ofrece esta capa de compatibilidad con `OpenAI`. Requiere su propio SDK (`google-genai`) y una adaptación más profunda del código, como se vio en la sección de este mismo documento sobre por qué no se puede simplemente redirigir `genai.Client` hacia Ollama.

Proveedor	¿Compatible con la clase <code>OpenAI</code> ?	Para qué conviene usarlo
Ollama	Sí	Uso normal, sin limitaciones relevantes
Claude	Sí (beta)	Solo pruebas rápidas; para producción, mejor el SDK nativo de Anthropic
Gemini	No	Siempre hace falta el SDK propio (<code>google-genai</code>)

1.5 DIA-1: Completando el laboratorio (versión Gemini)

1.5.1 La función messages_for() + summarize(url) — uniendo todas las piezas

En vez de armar el prompt a mano cada vez, se encapsula en una función reutilizable. En la versión original de OpenAI devuelve una lista de diccionarios **role/content**; en la versión adaptada a Gemini, un diccionario con dos claves separadas:

```
# Define nuestro system prompt - puedes experimentar con esto después, cambiando la
última oración a "Responde en markdown en español."

system_prompt = """
Eres un asistente que analiza el contenido de un sitio web,
y ofrece un resumen corto, ignorando el texto que pueda ser de navegación.
Responde en markdown. No envuelvas el markdown en un bloque de código - responde
solo con el markdown.
"""

# Define nuestro user prompt

user_prompt_prefix = """
Aquí está el contenido de un sitio web.
Proporciona un resumen corto de este sitio web.
Si incluye noticias o anuncios, resúmelos también.
"""

# Probemos esta utilidad

ed = fetch_website_contents("https://edwarddonner.com")
print(ed)

# Mira cómo esta función arma el prompt para Gemini

def messages_for(website):
    return {
        "system_instruction": system_prompt,
        "contents": user_prompt_prefix + website
    }
```

summarize(url) — uniendo todas las piezas

Esta es la función que integra scraping + prompt + llamada al modelo, adaptada a Gemini:

```
# Y ahora: llama a la API de Gemini. ¡Te familiarizarás mucho con esto!

def summarize(url):
    website = fetch_website_contents(url)
    prompt = messages_for(website)
    response = client.models.generate_content(
        model="gemini-3.6-flash",
        config=genai.types.GenerateContentConfig(system_instruction=prompt
        ["system_instruction"]),
        contents=prompt["contents"]
    )
    return response.text
```

Paso	Que hace
Fetch_website_contents(url)	Descarga y limpiar el HTML, devuelve texto (titulo + contenido, truncado a 2.000 caracteres)
Messages_for(website)	Arma el diccionario con system_instruction y contents
Client.models.generate_content(...)	Llama a Gemini: separa el system prompt (en config) del user prompt (en content)
Return responde.text	Devuelve solo el texto de la respuesta, sin los metadatos extra

Detalle importante: ejecutar def no hace nada todavía

Correr una celda con **def summarize(url): ...** solo **define** la función – no dispara ninguna llamada a internet ni al modelo. Recien pasa algo cuando se la invoca en otra celda, por ejemplo, **summarize("https://edwarddonner.com")**.

1.5.2 display_summary(url) – mostarlo formateado

```
# Una función para mostrar esto de forma más agradable en la salida, usando markdown

def display_summary(url):
    summary = summarize(url)
    display(Markdown(summary))
```

0.0s Python

El resultado crudo de **summarize()** viene "todo en una línea", sin formato. Esta función lo pasa por **display(Markdown(...))** para que se vea con títulos, negritas y saltos de línea, en vez de texto plano feo.

```
display_summary("https://edwarddonner.com")
```

12.2s Python

Salida:

El Templo de Inteligencia Artificial de Ed Donner

Felicidades, has llegado al sitio web oficial de **Edward "Ed" Donner**, un ex-Director de JPMorgan y emprendedor en serie que necesita desesperadamente que sepas lo apasionado que es por la IA.

Resumen del Personaje

- **El origen de su éxito:** A Ed le gusta tanto hablar sobre LLMs (Modelos de Lenguaje) que sus amigos, completamente hartos de escucharlo hablar solo, lo convencieron de crear cursos en Udemy. Ahora aburre a más de 900,000 estudiantes en todo el mundo.
- **Sus pasatiempos:** Produce música electrónica (él mismo aclara que es *muy mala*) y lee *Hacker News* asintiendo con la cabeza para fingir que entiende lo que lee.
- **Narcisismos de alta tecnología:** Por si no tienes suficiente con el Ed real, creó un **Avatar Digital** para que puedas chatear con su versión cibernética las 24 horas del día.

Anuncios y Noticias (Directo desde el Futuro)

Ed no solo programa, también parece viajar en el tiempo, ya que nos deja ver sus futuros "recursos" y cursos programados entre 2025 y 2026:

- **Mayo 2025:** La guía existencial para saber en qué orden deberías gastar tu dinero en sus cursos.
- **Septiembre 2025:** *AI Engineering MLOps Track*, para que aprendas a mandar IAs a producción antes de que se caiga el servidor.
- **Enero 2026:** *AI Builder con n8n*, enfocado en crear agentes de voz (porque claramente el mundo necesita más robots hablándonos).
- **Febrero 2026:** *AI Coder: Vibe Coder a Agentic Engineer*, un curso diseñado para convertir a los programadores "por intuición" en ingenieros reales.

1.5.3 Limitación del scraper actual: sitios con JavaScript + Playwright + Screenshots de notebook

`fetch_website_contents` (con `requests` + `BeautifulSoup`) solo descarga el HTML **crudo**, sin ejecutar JavaScript. En sitios modernos (React, Vue, Angular), el contenido real se genera recién cuando un navegador ejecuta ese JavaScript — así que el scraper actual encuentra una página casi vacía (ej. `openai.com` falla con este método).

La alternativa: Playwright

Playwright abre un navegador real (invisible, "headless"), deja que el JavaScript se ejecute, espera a que la página termine de cargar (auto-wait), y recién ahí extrae el HTML ya completo. El resto del proceso (limpieza con `BeautifulSoup`) queda igual.

Instalación (gratis, sin límites ni suscripción):

```
powershell

uv pip install playwright
playwright install
```

Función de scraping con Playwright:

```
from playwright.sync_api import sync_playwright
from bs4 import BeautifulSoup

def fetch_website_contents_playwright(url):
    with sync_playwright() as p:
        browser = p.chromium.launch() # abre Chromium invisible
        page = browser.new_page()
        page.goto(url) # navega a la url
        html = page.content() # HTML YA renderizado, con JS ejecutado
        browser.close()

    soup = BeautifulSoup(html, "html.parser")
    title = soup.title.string if soup.title else "No title found"
    if soup.body:
        for irrelevant in soup.body(["script", "style", "img", "input"]):
            irrelevant.decompose()
        text = soup.body.get_text(separator="\n", strip=True)
    else:
        text = ""
    return (title + "\n\n" + text)[:2_000]
```

	requests (actual)	Playwright (alternativa)
Ejecuta JavaScript	No	Si
Funciona en sitios React/Vue	No	Si
Velocidad	Rapida	Más lento (abre un navegador real)
Costo	Gratis	Gratis (open source, de Microsoft)
Recomendación de uso	Mayoría de sitios estáticos	Solo los sitios que fallan por JS

Selenium es la otra alternativa mencionada por el profesor, aunque hoy (2026) **Playwright** es el estándar más recomendado para proyectos nuevos: más rápido, con auto-wait incorporado, y soporte multi-navegador desde una sola instalación.

Problemos con más sitios web

Ten en cuenta que esto solo funcionará en sitios web que puedan ser scrapeados usando este enfoque simplista.

Los sitios web renderizados con Javascript, como las apps de React, no aparecerán. Revisa la carpeta `community-contributions` para ver una implementación con Selenium que evita este problema. Necesitarás informarte sobre cómo instalar Selenium (¡pregúntale a ChatGPT!)

También los sitios web protegidos con CloudFront (y similares) pueden dar errores 403 - muchas gracias a Andy J por señalar esto.

Por muchos sitios web, funciona sin problemas!

```
[ ] display_summary("https://cnn.com")
```

Python

```
[ ] display_summary("https://anthropic.com")
```

Python

Un ejercicio extra para quienes disfrutan el web scraping

Puede que notes que si intentas `display_summary("https://openai.com")` - ¡no funciona! Eso es porque OpenAI tiene un sitio web sofisticado que usa Javascript. Hay muchas formas de evitar esto con las que algunos de ustedes pueden estar familiarizados. Por ejemplo, Selenium es un framework enormemente popular que ejecuta un navegador por detrás, renderiza la página, y te permite consultarla. Si tienes experiencia con Selenium, Playwright o un framework similar de automatización de navegador, siéntete libre de implementar una versión alternativa de las funciones de scraping en `scraper.py` (o en un módulo separado) usando una de estas herramientas. En la carpeta `community-contributions`, encontrarás ejemplos aportados por otros estudiantes, incluyendo una implementación con Selenium (¡gracias!)

1.5.4 Cierre del laboratorio: contribuciones comunitarias + ScreenShots

- Carpeta **community-contributions** en el repo: lugar para subir variantes propias del ejercicio (ej. alguien integró la API de Yahoo Finance para resumir movimientos de acciones).
- Se puede compartir el propio trabajo enviando un **Pull Request** (instrucciones en la guía de Git/GitHub del curso).
- Mensaje de cierre del profesor: este patrón simple (scrapear + resumir con un LLM) es la base de un caso de uso de negocio muy común en IA generativa — resumen y traducción de contenido — y vale la pena adaptarlo a un problema propio, personal o de negocio.

llm_engineering-EdDooner / community-contributions /

Add file ▾

...

ed-donner Merge pull request ed-donner#3871 from elton-bleta/tony/day2-solution 3d5fe9c · 5 days ago History

This branch is up to date with ed-donner/llm_engineering:main .

Contribute ▾ Sync fork ▾

Name	Last commit message	Last commit date
..		
Abhijith_HackTrack	Add HackTrack to community contributions	3 months ago
Ahmed Hafez Projects	AI Assistant Inventory managment system week 2 practice	3 months ago
Ahmed-Hafez/Week-2	clear notebook outputs	5 months ago
Arjav014	Merge pull request ed-donner#3380 from Arjav014/personal-assistant	3 months ago
Ashok	ashok chnages'	last month
CodeMaestroMS	Merge pull request ed-donner#3678 from CodeMaestroMS/codemaestrms/wee...	last month

llm_engineering-EdDooner / community-contributions /

↑ Top

Shield01/Week1	Built a technical assistance using llama3.2	9 months ago
Suyash/python_teacher	Added Suyash python_teacher contribution notebook	10 months ago
Sylvie	Sylvie's week1 exercise (cleared outputs)	3 months ago
Vagz1216	Bootcamp/Euclid: Add exception catching and traceback to Gradio UI	6 months ago
VenkatKrishna	Add Week 3 synthetic data generator community contribution	2 weeks ago
WebScrapersApp	Add Assaf week1 day2 exercise solution	11 months ago
abdoul	Merge pull request ed-donner#924 from Abdoulrashed/w-viii	11 months ago
adeyemi-kayode	feat(week1): created a technical assistant tool	7 months ago
aditya-soni-contributions	Added week1 day2 contribution	5 months ago
aditya_battlecard	Add Battlecard.ai: Autonomous Competitor Research Agent	9 months ago
adityachebiyyam/3_way_llm_conversation_showdown	Week2 3WayLLMConversation	6 months ago
ahmad19sep	Add email subject writer contribution	2 weeks ago
ahmed_eldamaty/week_1	contribution(week-1): add ManualMate project	3 weeks ago
ahmed_sohail	changed the user and system prompt tone	8 months ago
akhilasaiteja	Update README.md	5 months ago
alessandro-fugazza	Create stateful_chatbot.ipynb	4 months ago

1.6 FINAL-DIA-1: Ejercicio final – tu propia llamada a un LLM desde cero

El desafío del profesor

Después de construir el resumidor de páginas web, el profesor deja de dar el código armado y pide escribirlo desde cero, aplicado a una idea de negocio distinta. Entrega una plantilla con los pasos marcados pero vacíos:

```
# Paso 1: Crea tus prompts

system_prompt = "algo aquí"
user_prompt = """
    Puedes pegar
    mucho texto aquí
    """

# Paso 2: Arma la llamada a Gemini
# response = client.models.generate_content(model="gemini-3.6-flash",
# config=genai.types.GenerateContentConfig(system_instruction=system_prompt),
# contents=user_prompt)


# Paso 3: imprime el resultado
# print()
```

Cómo completarlo, paso a paso

1. **Pensar una idea de negocio distinta** a resumir páginas web. El profesor da dos ejemplos: resumir el contenido de un email, o generar un buen asunto (subject line) a partir del cuerpo de un correo.
2. **Escribir el system_prompt**: una instrucción clara que describa la tarea (ej. "Sos un asistente que lee un email y sugiere un asunto corto y claro para él").
3. **Escribir el user_prompt**: el contenido real a procesar (el texto del email, por ejemplo).
4. **Armar la lista messages**: los dos diccionarios (**system** + **user**), como se vino haciendo en todo el laboratorio. El profesor aclara: usar herramientas de IA para ayudarte con esto **no es hacer trampa**.
5. **Descomentar y completar response** =: la llamada al modelo (en la versión adaptada a Gemini: `client.models.generate_content(...)`, en vez de `openai.chat.completions.create(...)` como en el video original).
6. **Descomentar e imprimir el resultado**: con `response.text` (Gemini) en vez de `response.choices[0].message.content` (OpenAI).

1.6.1 Ejercicio extra opcional: scraping "industrial" + 5 ideas de desafío para practicar (investigadas) + Consejo general para cualquiera de estos desafíos

Para quienes ya conocen Selenium o Playwright, el profesor sugiere construir una versión más robusta del resumidor web, que sí funcione en sitios renderizados con JavaScript — hay ejemplos de otros estudiantes en **community-contributions**, incluida una versión con Playwright.



Balance del Día 1 (según el profesor)

Ya sabés hacer:

- Usar Ollama para correr LLMs localmente
- Escribir código que llama a modelos frontera
- Distinguir system prompt de user prompt
- Resumir contenido — aplicable a muchos problemas comerciales

Mañana (Día 2) vas a poder:

- Conocer los pasos exactos hacia el dominio de LLM Engineering
- Reconocer los principales modelos frontera y cómo usarlos

Dato de cierre: el profesor calcula, en broma, que con todo esto ya estás en el **2.5% del camino** hacia ser "maestro de LLM Engineering".

5 ideas de desafío para practicar (investigadas)

1. Generador de asunto para emails

Basado en los usos más comunes y efectivos de prompt engineering para tareas de negocio, estas son cinco variantes del mismo patrón (system_prompt + user_prompt + llamada al modelo) para practicar, de menor a mayor complejidad:

Por qué es un buen desafío inicial: es casi idéntico al ejemplo del profesor, ideal para practicar la mecánica sin complicarse con la idea.

2. Análisis de sentimiento de reseñas de producto

system_prompt: "Sos un analista que clasifica reseñas de clientes como Positiva, Negativa o Neutral, y explica en una frase por qué". **user_prompt:** una reseña real (se puede tomar de cualquier producto en Amazon, MercadoLibre, etc.).

Por qué es útil: es uno de los casos de uso más comunes de LLMs en negocios reales — analizar feedback de clientes a escala, sin tener que leer cada reseña a mano.

3. Resumen con restricciones de formato ("explícamelo como si tuviera 5 años")

system_prompt: "Explicá el siguiente texto técnico como si hablaras con alguien de 5 años, usando máximo 3 oraciones". **user_prompt:** un párrafo técnico o científico complejo (por ejemplo, de Wikipedia).

Por qué es interesante: demuestra que agregar restricciones concretas (edad del público, cantidad de oraciones) al prompt mejora mucho la calidad del resultado, comparado con un simple "resumí esto".

4. Clasificador de tickets de soporte

system_prompt: "Sos un clasificador que lee un ticket de soporte técnico y responde solo con una categoría: Facturación, Bug técnico, Consulta general o Urgente". **user_prompt:** el texto de un ticket inventado o real (ej. "no puedo iniciar sesión desde ayer, ya reinicié todo").

Por qué es un buen ejercicio: introduce la idea de **clasificación** (no solo resumen/generación) — pedirle al modelo que elija entre opciones fijas, útil como primer paso hacia lo que después será RAG y agentes en el curso.

5. Traductor con tono personalizado

system_prompt: "Traducí el siguiente texto al español, pero con un tono informal y chileno (modismos incluidos)". **user_prompt:** un párrafo en inglés (por ejemplo, un fragmento de una noticia).

Por qué es divertido y educativo: el propio profesor menciona la traducción como ejemplo de variante en community-contributions — y permite ver claramente cómo un mismo texto cambia radicalmente de "personalidad" según las instrucciones del system prompt, reforzando la lección central del día.

Consejo general para cualquiera de estos desafíos

Según buenas prácticas de prompt engineering: los mejores resultados salen cuando el system_prompt incluye **parámetros concretos y medibles** (largo máximo, tono, formato de salida, público objetivo) en vez de instrucciones vagas tipo "hacelo bien". Por ejemplo, "resumí esto en 3 oraciones para un público general" funciona mejor que simplemente "resumí esto".


1.7 DIA 2: El panorama open-source y las tres formas de usar un LLM

Open-Source



Llama from Meta
Mixtral from Mistral
Qwen from Alibaba Cloud
Gemma from Google
Phi from Microsoft
DeepSeek from DeepSeek AI
GPT-OSS from OpenAI

OPEN-SOURCE



Three ways to use models



Chat interfaces

Like ChatGPT



Cloud APIs

LLM API

Frameworks like LangChain

Managed AI cloud services:

- Amazon Bedrock
- Google Vertex
- Azure ML



Direct inference

With the HuggingFace Transformers library

With Ollama to run locally



1.7.1 ¿Qué separa "modelo frontera" de "open-source" para el profesor? + Panorama de modelos de open-source

¿Qué separa "modelo frontera" de "open-source" para el profesor?

El profesor aclara un matiz de vocabulario: reserva el término "**modelo frontera**" para los modelos de código **cerrado** (GPT, Claude, Gemini), aunque técnicamente algunos modelos open-source también estén en la frontera de lo posible.

2. Panorama de modelos open-source

Empresa	Modelo	Parametros / dato clave	Fuente
Meta	Llama	Llama 3.2 viene en 1B y 3B (no solo 3B como se dijo en el video) — ollama run llama3.2 baja la de 3B por defecto	Confirmado en registry.ollama.ai y llama.com
Mistral AI (Francia)	Mixtral	Arquitectura Mixture of Experts (MoE) : varios sub-modelos especializados, se activa solo el necesario según la pregunta	—
Alibaba Cloud (China)	Qwen	Modelo muy potente, menos conocido que Llama — el profesor lo recomienda especialmente	-
Google	Gemma	"Primo open-source" de Gemini; versión más chica de 270M de parámetros (la que se probó con Ollama en el Día 1)	-
Microsoft	Phi	Buena en tool calling y uso comercial; la usada en el Día 1 (phi3)	-
DeepSeek AI (China)	DeepSeek	Ver sección 3	-
OpenAI	GPT-OSS	Ver sección 4	-

Por qué Meta abrió sus modelos (lectura del profesor)

Una interpretación "poco caritativa" que plantea el profesor: Meta no lograba competir con OpenAI/Anthropic en tener el modelo más potente del momento, y encontró en el open-source una forma de diferenciarse y mantenerse en los titulares. Funcionara o no como estrategia deliberada, hoy Meta es sinónimo de liderazgo en IA abierta.

1.7.2 El fenómeno DeepSeek + Tamaño real del modelo

Por que causo tanto revuelo (no fue por ser “el mas potente”)

DeepSeek no supera a GPT-5 ni a Claude en capacidad — lo que causó el revuelo fue la **eficiencia del entrenamiento**:

	Costo de entrenamiento
GPT (OpenAI)	Más de \$100 millones USD (estimado)
DeepSeek-V3	~\$5,6 millones USD (2.788 millones de horas de GPU H800), confirmado en el paper oficial de DeepSeek

Tamaño real del modelo

Confirmado en Hugging Face y el paper oficial: **DeepSeek-V3/R1 tiene 671.000 millones de parámetros totales, con 37.000 millones activos por token** — es un modelo **MoE**, igual que Mixtral. Demasiado grande para correr en una PC normal (según estimaciones de hardware, requeriría del orden de 1.300+ GB de VRAM, o un clúster de 16 GPUs A100 de 80GB).

Cómo se arman las versiones chicas que sí corren en Ollama (destilación)

Cuando corriste ollama run llama3.2 o cuando corres ollama run deepseek-r1:8b, en ambos casos Ollama está ejecutando, por dentro, un modelo con la misma **arquitectura** de Llama (misma "forma" de red neuronal). La diferencia está en **qué aprendió** ese modelo durante su entrenamiento — y ahí es donde entra la destilación.

Cómo funciona el proceso, paso a paso:

1. DeepSeek entrena su modelo grande (671B parámetros) de la forma tradicional: con enormes cantidades de texto de internet.
2. Una vez entrenado, le hacen miles de preguntas de razonamiento (matemática, código, lógica) a ese modelo grande, y guardan sus respuestas — sobre todo el "paso a paso" que usa para llegar a la solución. Esto genera un dataset de **800.000 ejemplos** de razonamiento de alta calidad.
3. Ese dataset se usa para **re-entrenar** un modelo de Llama o Qwen que ya existía (por ejemplo, Llama 3.1-8B), mediante un proceso llamado **fine-tuning supervisado (SFT)**: al modelo chico se le muestran, una y otra vez, pares de "pregunta → respuesta razonada paso a paso" (los 800.000 ejemplos generados por DeepSeek), y sus parámetros internos se ajustan poco a poco para que aprenda a reproducir ese mismo estilo de razonamiento — sin empezar de cero, sino partiendo de lo que Llama ya sabía.

Entonces, ¿qué es exactamente lo que se descarga con ollama pull deepseek-r1:8b?

Se descarga un modelo con la **arquitectura de red neuronal de Llama** (las mismas "capas" y conexiones internas que tiene cualquier Llama 3.1-8B), pero cuyos parámetros internos fueron reajustados con las enseñanzas de razonamiento de DeepSeek. Es como tomar el "cerebro" físico de Llama y volver a entrenarlo con material nuevo — la estructura del cerebro sigue siendo la misma, pero lo que sabe hacer cambió.

Por eso Ollama lo etiqueta con el nombre deepseek-r1, aunque técnicamente sea un Llama por dentro: lo que identifica al modelo, de cara al usuario, es **de dónde viene el conocimiento** (DeepSeek), no la arquitectura que lo ejecuta (Llama). Esto no es algo que Ollama "adapte" por su cuenta — el propio equipo de DeepSeek hizo este re-entrenamiento y publicó el resultado así, y Ollama simplemente lo empaquetó para que se pueda correr fácil, igual que hace con cualquier otro modelo. 4. El resultado es un modelo que sigue siendo "Llama" o "Qwen" por dentro (misma arquitectura, mismo tamaño), pero que **razona mucho mejor** que la versión original, porque aprendió a imitar el estilo de razonamiento del DeepSeek grande.

Por qué se llama "destilación": la idea viene de la química — destilar es extraer la "esencia concentrada" de algo. **Acá se extrae el "conocimiento de razonamiento"** del modelo gigante y se concentra en uno chico, sin necesitar todo el tamaño y costo del original.

Por qué esto importa en la práctica: significa que cuando corrés deepseek-r1:8b en tu PC, **no estás corriendo "DeepSeek" en su forma original** — estás corriendo un Llama 3.1-8B que fue mejorado con las enseñanzas de DeepSeek. Confirmado en la documentación oficial de Ollama: el modelo de 8B deriva literalmente de **Llama 3.1-8B-Base**, y el de 70B deriva de **Llama 3.3-70B-Instruct** — ambos conservan la licencia original de Llama, no una licencia de DeepSeek.

1.7.3 GPT-OSS: la versión abierta de OpenAI + Las tres formas de usar cualquier modelo de IA + Diferencia entre Hugging Face Transformers y Ollama (ambas son "inferencia directa")

Corrección sobre el video: el profesor menciona que la versión chica es de "120 mil millones" — esto es un error de transcripción/lapsus. Los datos oficiales, confirmados por múltiples fuentes técnicas coincidentes (lanzamiento oficial del 5 de agosto de 2025, licencia Apache 2.0):

Modelo	Parámetros totales	Parámetros activos (MoE)	Hardware necesario
gpt-oss-20b (el probado en el Día 1)	20.910.000.000 (20.91B)	3.610.000.000 (3.61B)	Cabe en 16 GB — consumer hardware
gpt-oss-120b	116.830.000.000 (116.83B)	5.130.000.000 (5.13B)	Cabe en una sola GPU de 80 GB (ej. NVIDIA H100)


Ambos son modelos de razonamiento (soportan chain-of-thought, niveles ajustables de esfuerzo de razonamiento) — coincide con el bloque de "Thinking..." que se vio al probar **gpt-oss:20b** en el Día 1.

La teoría del profesor sobre por qué OpenAI lo abrió

Plantea que quizás DeepSeek forzó la jugada: al abrir un modelo casi al nivel de GPT de forma gratuita, le quitó a OpenAI parte de su ventaja de "tener lo mejor y mantenerlo cerrado" — dato de contexto real: GPT-OSS es la primera apertura de pesos de OpenAI desde GPT-2 en 2019, más de 6 años de modelos cerrados.

Las tres formas de usar cualquier modelo de IA

Aplica tanto a modelos cerrados (GPT, Claude, Gemini) como abiertos (Llama, Qwen, Gemma):



Forma	Ejemplos	Que es realmente
Interfaces de chat (producto)	ChatGPT	No es “solo el modelo” – es un producto : interfaz de usuario, memoria, búsqueda web, todo construido por ingenieros sobre el modelo base
APIs en la nube	Llamadas directas (OpenAI, Gemini — lo hecho en el Día 1), frameworks como LangChain, servicios gestionados (Amazon Bedrock, Google Vertex AI, Azure ML), Groq, OpenRouter	Se llama a un modelo corriendo en servidores de un tercero
Inferencia directa	Hugging Face Transformers, u Ollama	Se corre el modelo con hardware propio, sin depender de ningún servidor externo

Diferencia entre Hugging Face Transformers y Ollama (ambas son "inferencia directa")

- **Hugging Face Transformers:** se toma el código fuente original (Python/C++) del modelo y sus pesos, y se corre directamente en el propio intérprete de Python — más flexible, pero más técnico.
- **Ollama:** empaqueta todo eso de forma optimizada – código en C++ eficiente, pesos comprimidos en archivos **GGUF** – y da una API local lista para usar en pocos pasos. Es mas simple, peros solo soporta los modelos específicos que Ollama empaqueto.

1.7.4 Que es "inferencia"

Qué es "inferencia"

Término técnico que se va a usar constantemente en el curso: **inferencia = correr un modelo**. Es el proceso de darle una entrada nueva a un modelo ya entrenado y obtener una salida (una respuesta).

Otros conceptos mencionados de pasada

- **Grok (con Q):** un tipo de servicio para correr modelos open-source a gran velocidad en la nube usando hardware propietario — distinto de **Grok (con K)**, el modelo de IA de Elon Musk/xAI. El profesor advierte explícitamente sobre esta confusión de nombres.
- **OpenRouter:** plataforma que redirige pedidos a muchos proveedores de modelos distintos desde un solo punto de entrada.